

Слкуни Герман РТ5-61Б

Лабораторная работа 5

Задание

1. Выберите набор данных (датасет) для решения задачи классификации или регрессии.
2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
3. С использованием метода `train_test_split` разделите выборку на обучающую и тестовую.
4. Обучите следующие ансамблевые модели: две модели группы бэггинга (бэггинг или случайный лес или сверхслучайные деревья); AdaBoost; градиентный бустинг.
5. Оцените качество моделей с помощью одной из подходящих для задачи метрик. Сравните качество полученных моделей.

Описание датасета

Набор данных `breast_cancer` (Wisconsin Diagnostic Breast Cancer) содержит:

Объекты: 569 образцов опухолевых клеток.

Признаки (30 числовых):

Для каждого из 10 измеряемых свойств (`radius`, `texture`, `perimeter`, `area`, `smoothness`, `compactness`, `concavity`, `concave points`, `symmetry`, `fractal dimension`) вычислены три статистики: `mean` (среднее по клеткам), `se` (стандартная ошибка), `worst` (наихудшее значение). Целевая переменная (`target`): – бинарная, где 0 = malignant (злокачественная) 1 = benign (доброкачественная)

```
In [1]: from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler

# 1) Загрузка и разбивка
```

```

data = load_breast_cancer()
X_train, X_test, y_train, y_test = train_test_split(
    data.data, data.target, test_size=0.3, random_state=42, stratify=data.ta
)

scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

# Проверка на наличие нулевых значений
print("Проверка на нули в данных:")
print("X_train содержит нули:", (X_train == 0).any())
print("X_test содержит нули:", (X_test == 0).any())

print("Features (30):", data.feature_names)
print("Target names:", data.target_names)
print("X shape:", data.data.shape) # (569, 30)
print("y distribution:",
      {name: int((data.target==i).sum())
       for i,name in enumerate(data.target_names)})

```

Проверка на нули в данных:

X_train содержит нули: False

X_test содержит нули: False

Features (30): ['mean radius' 'mean texture' 'mean perimeter' 'mean area'
'mean smoothness' 'mean compactness' 'mean concavity'
'mean concave points' 'mean symmetry' 'mean fractal dimension'
'radius error' 'texture error' 'perimeter error' 'area error'
'smoothness error' 'compactness error' 'concavity error'
'concave points error' 'symmetry error' 'fractal dimension error'
'worst radius' 'worst texture' 'worst perimeter' 'worst area'
'worst smoothness' 'worst compactness' 'worst concavity'
'worst concave points' 'worst symmetry' 'worst fractal dimension']

Target names: ['malignant' 'benign']

X shape: (569, 30)

y distribution: {'malignant': 212, 'benign': 357}

```

In [2]: # 2) Инициализация моделей
from sklearn.ensemble import (
    BaggingClassifier, RandomForestClassifier, ExtraTreesClassifier,
    AdaBoostClassifier, GradientBoostingClassifier
)

models = {
    "Bagging (DT)": BaggingClassifier(random_state=42),
    "RandomForest": RandomForestClassifier(random_state=42),
    "ExtraTrees": ExtraTreesClassifier(random_state=42),
    "AdaBoost (DT)": AdaBoostClassifier(random_state=42),
    "GradientBoosting": GradientBoostingClassifier(random_state=42),
}

# 3) Обучение и оценка
for name, mdl in models.items():
    mdl.fit(X_train, y_train)
    print(f"{name}: {mdl.score(X_test, y_test):.3f}")

```

```
Bagging (DT): 0.959
RandomForest: 0.936
ExtraTrees: 0.971
AdaBoost (DT): 0.959
```

```
/home/mrcreepton/anaconda3/lib/python3.12/site-packages/sklearn/ensemble/_weight_boosting.py:527: FutureWarning: The SAMME.R algorithm (the default) is deprecated and will be removed in 1.6. Use the SAMME algorithm to circumvent this warning.
```

```
warnings.warn(
```

```
GradientBoosting: 0.942
```

In []:

In []: